

4.6 Счётчики с короткой памятью HyperLogLog и эксперимент Стенли Мильграма

В этом, заключительном параграфе главы мы рассмотрим ещё один сюжет на стыке теории чисел, теории вероятностей и информатики — задачу, в которой важно *подсчитывать число различных объектов* в огромном потоке данных, не имея возможности хранить их все. Это пригодится для задачи, на первый взгляд несвязанной с криптографией: измерения «социальных расстояний» в больших сетях, и проверки знаменитой гипотезы Стенли Мильграма о шести рукопожатиях.

Изложение в этом параграфе опирается на главу 7 книги Литвак и Райгородского «Кому нужна математика?»^[2], которую мы рекомендуем для самостоятельного изучения.

Задача подсчёта различных элементов

Представьте, что вы работаете в большой интернет-компании и хотите узнать: сколько *уникальных* пользователей зашло сегодня на сайт? Не общее число обращений (его легко посчитать инкрементируя счётчик при каждом запросе), а именно *различных* людей.

Точное решение. Простое и очевидное: завести множество (например, хеш-таблицу из §4.5), и при каждом приходящем идентификаторе пользователя проверять, есть ли он там; если нет — добавить и увеличить счётчик. По окончании дня размер множества — ответ.

Проблема. Если число уникальных пользователей — сотни миллионов или миллиарды, такая таблица занимает гигабайты памяти. Для одной задачи на одном сервере — допустимо. А если таких задач тысячи, и каждая на каждом из тысяч серверов? Память становится узким местом.

Возникает естественный вопрос: можно ли подсчитать число различных элементов в потоке *приблизённо*, но используя *гораздо меньше памяти*? Например, дать ответ с относительной погрешностью $\pm 2\%$, заняв всего несколько килобайт?

Удивительно, но ответ положительный. И построение такого алгоритма опирается на красивые идеи теории вероятностей и — что нам особенно интересно — использует хеш-функции, родственные тем, что мы изучали в §4.5.

Идея: «самый длинный хвост нулей»

Алгоритм, который мы сейчас опишем (он называется **HyperLogLog**, предложен Филиппом Флажолем и его коллегами в 2007 году), основан на одной красивой вероятностной идее.

Пусть у нас есть «хорошая» хеш-функция h , которая для каждого входного объекта (например, идентификатора пользователя) выдаёт случайную на вид последовательность из L битов. Слово «случайную» означает: для разных входов биты выглядят как независимые подбрасывания монеты^[3].

Наблюдение. Если число $h(x)$ действительно ведёт себя случайно, то рассмотрим, сколько *нулей подряд* стоит в начале двоичной записи $h(x)$.

- Вероятность, что первый бит — ноль: $1/2$.
- Вероятность, что первые два бита — нули: $1/4$.
- Вероятность, что первые k битов — нули: $1/2^k$.

Наглядно эта закономерность показана на рис. 4.17.

```
010101...
0000111...
001011...
0000010... «длинный» «хвост нулей» — редкое событие
1110...
```

Рис. 4.17. Иллюстрация двоичных хешей. Чем длиннее «хвост нулей» в начале, тем реже такое событие.

Иначе говоря, если в потоке встречается элемент x , такой что $h(x)$ начинается, скажем, с 20 нулей подряд, это значит, что в потоке *скорее всего побывало порядка* $2^{20} \approx 10^6$ *различных элементов* — иначе крайне маловероятно увидеть такое редкое событие.

Базовый алгоритм («одиночный счётчик»).

! Алгоритм: наивный счётчик различных элементов

1. Заведём одну переменную $M = 0$.
2. Для каждого приходящего элемента x потока:
 1. вычислим $h(x)$;

2. посчитаем число $\rho(h(x))$ — длину начального блока нулей в $h(x)$, плюс единица;
 3. обновим $M \leftarrow \max(M, \rho(h(x)))$.
3. На выходе оценим число различных элементов как $\hat{n} = 2^M$.

Память. Чтобы хранить M от 0 до L (где L — длина хеша, скажем, 32 бита), достаточно *шести битов памяти*. Шесть битов — чтобы оценить число различных элементов в потоке любой длины!

Проблема. Эта оценка очень шумная: одно «случайно длинное» обнуление сбивает её в большую сторону, а его отсутствие — в меньшую. Дисперсия чудовищная.

Идея «несколько счётчиков»

Чтобы сгладить случайные колебания, разделим поток на много подпотоков и усредним результаты. Это и есть алгоритм HyperLogLog.

! Алгоритм: HyperLogLog (упрощённая схема)

1. Выберем число b — скажем, $b = 10$, — и заведём $2^b = 1024$ независимых счётчика $M_0, M_1, \dots, M_{2^b-1}$. Каждый счётчик — 6 битов.
2. Для каждого приходящего элемента x :
 1. вычислим $h(x)$ длины L ;
 2. первые b битов $h(x)$ интерпретируем как номер счётчика j , $0 \leq j < 2^b$;
 3. к остальным $L - b$ битам применяем правило: ρ = длина начального блока нулей плюс 1;
 4. обновляем: $M_j \leftarrow \max(M_j, \rho)$.
3. На выходе оцениваем

$$\hat{n} = \alpha_b \cdot 2^b \cdot \left(\frac{1}{2^b} \sum_{j=0}^{2^b-1} 2^{-M_j} \right)^{-1}, \quad (1)$$

где α_b — известная константа корректировки (для $b = 10$ примерно 0.7213).

Почему так? Формула в третьем шаге — это *гармоническое среднее* величин 2^{M_j} , а не простое арифметическое. Гармоническое среднее устойчиво к выбросам (одно случайно большое M_j его существенно не искажает) — именно поэтому HyperLogLog так точен.

⚠ Теорема 4.29. точность HyperLogLog

Относительная погрешность оценки $\hat{n}$ по сравнению с истинным значением n имеет порядок $1.04/\sqrt{2^b}$. При $b = 10$ это примерно 3.25%; при $b = 14$ — около 0.81%.

Память. При $b = 14$ имеется $2^{14} = 16\,384$ счётчиков по 6 битов — всего ≈ 12 КБ. И этим объёмом мы оцениваем число уникальных элементов в потоке длиной до $\approx 10^{18}$ с точностью около 1%! (рис. 4.18)



Рис. 4.18. Множество счётчиков HyperLogLog. Каждый запоминает максимальную длину «хво-

💡 Это интересно: где работает HyperLogLog

HyperLogLog встроен в Redis (популярную систему кэширования), в Google BigQuery (язык запросов к огромным базам данных), в систему аналитики ВКонтакте, в инфраструктуру PostgreSQL и многих других сервисов. Когда вы видите в личном кабинете рекламной системы оценку «охват: 3,5 млн уникальных пользователей», очень вероятно, что под капотом работает именно этот алгоритм.

Эксперимент Стенли Мильграма

Теперь, когда у нас в руках мощный инструмент для подсчёта уникальных объектов, обратимся к классической задаче из социологии, которую Литвак и Райгородский подробно разбирают в главе 7 своей книги.

Историческое введение. В 1960-х годах американский социальный психолог **Стенли Мильграм** (1933–1984) задался необычным вопросом: *насколько на самом деле «велик» мир?* Точнее: если выбрать наугад двух человек на разных концах страны, через сколько посредников можно их связать?


В 1967 году Мильграм провёл свой знаменитый эксперимент. Участникам в Канзасе и Небраске были даны письма с просьбой передать их некоему адресату в Бостоне, причём *нельзя* было отправлять напрямую — только через личного знакомого, который, как кажется участнику, может быть ближе к получателю; тот, в свою очередь, выбирал следующего знакомого, и так далее.

Удивительный результат. Большинство писем, дошедших до адресата, преодолевали путь *в среднем за 5–6 пересылок*. Так родилась знаменитая гипотеза «шести рукопожатий»: между любыми двумя людьми на Земле в среднем стоит лишь шесть посредников.

Современная проверка. Эксперимент Мильграма страдал серьёзными методологическими дефектами: 1/ подавляющее большинство писем (около 80%) до адресата так и не дошли; 2/ выборка была очень ограниченной (всего около 300 писем); 3/ «знакомые» отбирались не случайно, а с предположением о близости к получателю.

В современную эпоху, когда подавляющая часть знакомств и контактов перешла в цифровой формат, задачу можно проверить иначе: *построить граф знакомств целиком* и измерить кратчайшие расстояния. Именно это в 2011 году проделали исследователи в рамках одной известной социальной сети — они проанализировали данные *всех* её пользователей (на тот момент — около 720 миллионов человек) и более 69 миллиардов «дружеских связей».

Что они обнаружили. Средняя длина кратчайшего пути между двумя случайно выбранными пользователями оказалась равной *4,74 рукопожатия*. Иначе говоря, в современных социальных сетях гипотеза Мильграма не просто подтверждается, а даже *улучшается*: между двумя пользователями стоит в среднем менее пяти промежуточных знакомых, а не шесть. Принято округлять это число до 4 — отсюда выражение «четыре рукопожатия» (рис. 4.19).



4 рукопожатия = 4 ребра в графе знакомств

Рис. 4.19. «Четыре рукопожатия»: между Алисой и Яковом стоят всего трое промежуточных зна-

💡 Это интересно: «шесть рукопожатий» в литературе

Идея «малого мира» проникла в массовую культуру: пьеса Джона Гуэра «Six Degrees of Separation» (1990), фильм с тем же названием, многочисленные «эстафеты знакомств». В науке термин **small-world network** стал важным понятием в теории графов и сетевой социологии.

При чём здесь HyperLogLog?

Возникает вопрос: *как именно* вычислить среднюю длину кратчайшего пути в графе из 720 миллионов вершин и 69 миллиардов рёбер? Прямой подсчёт всех пар (а их $\binom{720 \cdot 10^6}{2} \approx 2,6 \cdot 10^{17}$) непосильно даже для самых мощных кластеров.

Здесь и приходит на помощь HyperLogLog (а также его «родственники» — алгоритмы вероятностного подсчёта). Идея, идущая в реальном анализе, такова:

! Алгоритм: оценка расстояний в графе через подсчёт «соседей»

1. Для каждой вершины v заведём HyperLogLog-счётчик C_v .
2. Вначале добавим в C_v только саму вершину v . То есть $|C_v| = 1$.
3. На шаге $t = 1, 2, \dots, T$:
 - для каждой вершины v обновим $C_v \leftarrow C_v \cup \bigcup_{u: (u,v) \text{ — ребро}} C_u^{(t-1)}$,
 - то есть в C_v добавляются все вершины, до которых дошли соседи v на предыдущем шаге.
4. Величина $|C_v|$ после t шагов — это число вершин, до которых от v существует путь длины $\leq t$.

Где экономия памяти. Если бы мы хранили C_v как точное множество, для одной вершины пришлось бы выделить до 720 миллионов битов памяти — 90 мегабайт. Умножим на 720 миллионов вершин — получим 65 петабайт. Невозможно.

А поскольку HyperLogLog-счётчик занимает 12 КБ на вершину, всё хранилище уместается в $720 \cdot 10^6 \cdot 12 \text{ КБ} \approx 8,6 \text{ ТБ}$ — объём, который уже уместается в один большой серверный кластер.

Объединение HyperLogLog-счётчиков. У алгоритма есть ещё одно прекрасное свойство: **HLL-счётчики можно объединять**. Если C_1 оценивает мощность множества A , а C_2 — мощность B , то новый счётчик C , у которого $C[j] = \max(C_1[j], C_2[j])$, оценивает мощность $A \cup B$. Это позволяет распределять вычисления по тысячам машин и в конце «склеивать» результаты.

 **Важно: краткое резюме**

Современное измерение «социального расстояния» в больших сетях — это композиция нескольких идей:

1. теория графов даёт постановку задачи (кратчайшие расстояния);
2. теория чисел и хеширование (§4.5) обеспечивают «равномерное» распределение элементов;
3. теория вероятностей и алгоритм HyperLogLog позволяют оценивать мощности множеств за десятки тысяч раз меньшую память;
4. распределённые вычисления позволяют разнести работу по тысячам компьютеров.

От социологии — к стратегическим выводам

Эксперимент Мильграма и его цифровое продолжение — не просто забавный факт. Из него следуют важные вещи:

- *Информация распространяется быстро.* Новость, попавшая в социальную сеть, при равномерной передаче «через знакомых» теоретически охватывает всю сеть за 4–5 шагов. На практике это и наблюдается с вирусными мемами.
- *Эпидемии распространяются быстро.* В аналогичной модели заражения болезнь, передающаяся при контакте, охватывает большую долю населения за считанные «волны» контактов.
- *Цифровая приватность хрупка.* Если ваш друг знает всё о вас, его друг — через пять рукопожатий — статистически связан с миллионами людей. Любая утечка приватной информации распространяется по сети быстрее, чем кажется.
- *Поиск работы и идей.* Знаменитая работа социолога Марка Грановеттера 1973 года показала, что новые контакты, идеи, рабочие места часто приходят к нам не от близких друзей, а от «слабых связей» — знакомых второго и третьего уровня. Малый диаметр сети объясняет, почему такая стратегия работает.

💡 Это интересно: модель «малого мира» Уоттса–Строгаца

Математическая модель социальной сети, объясняющая эффект малого мира, была построена Дунканом Уоттсом и Стивеном Строгацем в 1998 году. Они показали: если у регулярной решётки добавить совсем немного случайных «дальних» рёбер, диаметр графа резко падает с линейного до логарифмического. Социальная сеть устроена именно так: большинство ваших связей — локальные (одноклассники, коллеги), но достаточно нескольких «дальних» — например, родственника в другом городе или знакомого по интернету, — чтобы вся сеть оказалась «компактной».

! Задачи для самостоятельной работы

1. Объясните, почему в наивном алгоритме одиночного счётчика оценка $\hat{n} = 2^M$ имеет такую большую дисперсию.
2. Пусть хеш-функция выдаёт строки по 8 битов. Сколько (в среднем) различных элементов нужно подать на вход, чтобы хотя бы у одного оказалось 6 нулей в начале хеша?
3. Объясните, почему гармоническое среднее устойчивее к выбросам, чем арифметическое. Приведите пример набора чисел, в котором эти средние существенно различаются.
4. Оцените, сколько памяти займёт HyperLogLog при $b = 12$, и какова при этом ожидаемая относительная погрешность.
5. * Почему в алгоритме оценки расстояний в графе нельзя просто хранить $|C_v|$ как число (это же 4 байта)? Зачем хранить целый HLL-счётчик?
6. * Среднее число рукопожатий в графе оценено как 4,74. Что в этой формулировке играет роль случайной величины, а что — константы? Какой стандартной операции теории вероятностей соответствует «среднее число»?