

# Когда нейросеть устойчива: оценки Липшицевости

## Сюжет: когда панда становится гиббоном

В 2014 г. Иэн Гудфеллоу и соавторы опубликовали ставшую знаменитой картинку (рис. 0.10): обычная фотография панды, которую современная нейросеть уверенно опознаёт как «panda» с вероятностью 57,7%. К каждому пикселю прибавлена крошечная, визуально незаметная человеку поправка. На обновлённой картинке сеть теперь уверенно (с вероятностью 99,3%) считает, что видит *гиббона*.




Рис. 0.10. Adversarial-атака на нейросеть (Goodfellow et al., 2014). Слева — оригинал, классифицирован как «panda» с уверенностью 57,7%. В центре — почти невидимое возмущение, масштабированное для наглядности. Справа — атакованный пример, классифицируется как «gibbon» с уверенностью 99,3%.

Этот эффект называется **adversarial-атакой** и долгое время считался экзотикой. Сейчас понятно: причина в простом числе, которое сопровождает любую функцию — её *константе Липшица*.

## Константа Липшица: формальное определение

### **i** Определение 0.5. Константа Липшица функции

Функция  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  называется **Липшицевой** с константой  $L > 0$ , если для любых  $x, y \in \mathbb{R}^n$  выполнено

$$\|f(x) - f(y)\| \leq L \|x - y\|. \quad (1)$$

Наименьшее  $L$ , для которого (0.9) выполнено, называется *константой Липшица* функции  $f$  и обозначается  $\text{Lip}(f)$ .

Содержательно  $\text{Lip}(f)$  показывает, во сколько раз может *усилиться* входное возмущение на выходе функции. Если

$\text{Lip}(f) = L$ , то малое возмущение  $\delta$  на входе может вызвать возмущение до  $L \cdot \|\delta\|$  на выходе.

**Пример.** Для линейного отображения  $f(x) = Wx$  имеем  $f(x) - f(y) = W(x - y)$ , откуда  $\|f(x) - f(y)\| \leq \|W\|_2 \cdot \|x - y\|$ , и константа Липшица — это в точности спектральная норма матрицы  $W$ :

$$\text{Lip}(Wx) = \|W\|_2 = \sigma_1(W). \quad (2)$$

Здесь  $\sigma_1(W)$  — наибольшее сингулярное число матрицы  $W$ . Вот *здесь* в нашу историю входит SVD из § 0.3.

## Композиция: Липшицева константа цепочки

### ⚠ Теорема 0.6. Композиция Липшицевых функций

Если  $f$  и  $g$  — Липшицевы с константами  $L_f$  и  $L_g$ , то их композиция  $f \circ g$  — тоже Липшицева, причём

$$\text{Lip}(f \circ g) \leq \text{Lip}(f) \cdot \text{Lip}(g). \quad (3)$$

**Доказательство.**  $\|f(g(x)) - f(g(y))\| \leq L_f \|g(x) - g(y)\| \leq L_f L_g \|x - y\|$ .  $\square$

## Применение к нейросети

Возьмём типичную нейросеть глубины  $K$ :

$$f(x) = \sigma(W_K \sigma(W_{K-1} \sigma(\dots \sigma(W_1 x))), \quad (4)$$

где  $W_i$  — матрицы весов,  $\sigma$  — поэлементная активация (ReLU, сигмоида, и т.п.). Для большинства активаций  $\text{Lip}(\sigma) \leq 1$  (для ReLU и tanh она равна 1, а для логистической сигмоиды — 1/4). По теореме 0.6:

$$\text{Lip}(f) \leq \prod_{i=1}^K \|W_i\|_2 \quad (5)$$

Это и есть тот «лишний рычаг», который объясняет уязвимость нейросетей. Если  $\|W_i\|_2 \approx 2$  для каждого слоя из  $K = 20$  слоёв, то возмущение на входе *потенциально* усиливается в  $2^{20} \approx 10^6$  раз. Невидимая поправка  $\delta$  с  $\|\delta\| = 10^{-3}$  может

вызвать изменение выхода до  $10^3$  — этого хватит, чтобы перебросить классификатор из одного класса в другой.

## Как защищаться: спектральная нормализация

Естественная стратегия: после каждого шага обучения нормализовать матрицу  $W_i$  так, чтобы  $\|W_i\|_2 = 1$ . Это и есть метод **Spectral Normalization** (Миято и соавт., 2018), сделавший обучение генеративных нейросетей (GAN) намного стабильнее.

Технически: на каждом шаге считаем  $\sigma_1(W)$  (с помощью одной итерации степенного метода — почти бесплатно!) и заменяем  $W \mapsto W/\sigma_1(W)$ .

```
def spectral_normalize(W, n_iter=1):
    """One step of power iteration to estimate sigma_1(W) and rescale."""
    u = np.random.randn(W.shape[0])
    for _ in range(n_iter):
        v = W.T @ u; v /= np.linalg.norm(v)
        u = W @ v; u /= np.linalg.norm(u)
    sigma_1 = u @ W @ v
    return W / sigma_1
```

💡 Это интересно

**Связь с устойчивостью в физике.** Похожая ситуация хорошо известна в теории динамических систем: если константа Липшица отображения  $> 1$ , малое возмущение начального условия экспоненциально нарастает (классический эффект бабочки в погодных моделях). Spectral Normalization можно рассматривать как искусственное гашение этого эффекта.