


"panda" 57%
(на самом деле — панда)



+ $\epsilon \cdot$

Adversarial-атака (схема, по Goodfellow et al. 2014)
 $\text{sign}(\nabla_{\mathbf{x}} J(\theta, \mathbf{x}, y))$
незаметный шум



=

"gibbon" 99%
(сеть видит гиббона)

