

Глава 2. Экономико-политические и статистическо-психологические парадоксы

Общий посыл: Для лучшего понимания и мотивации в восприятии материалов следующей главы было решено показать на нескольких парадоксах почему не всегда можно полагаться на рыночные механизмы и пускать все на самотек. Предварительно нужно разобраться с тем, какое может возникать равновесие, будет ли оно справедливым? Глава как раз начинается с таких парадоксов, в которых возникающее равновесие неэффективно (по Парето), но выйти из него не получается (об этом говорится уже в конце главы). Парадокс Кондорсе и теорема Эрроу показывают, что не всегда в принципе возможно сделать что-то справедливо (например, систему голосования, в общем случае). Важное место в главе занимает парадокс Симпсона. С одной стороны это статический парадокс (таковых в этой главе довольно много, поскольку для управленцев представляется важным правильно интерпретировать ту информацию и данные, которые доступны), с другой стороны, этот парадокс строит мостик к главе 4 и объяснению различных социальных эффектов, в данном случае связанных с процветанием альтруизма. Понимание таких закономерностей также представляется крайне полезным для управленцев, задачей которых является поддержание общества в социальном оптимуме и гармонии, стимулирование альтруизма на благо системы за счет рациональности (эгоизма) на уровне индивидуумов (еще точнее говоря, их генов) и “правильных” правил игры.

§ 1 Парадоксы Пигу–Найта–Даунса и Даунса–Томсона

Как минимум стоит рассказать как в этой книге

https://savvateev.xyz/books/zam_eko/zam_eko.pdf

Но можно поподробнее немного. См. также видео

https://vkvideo.ru/video-60770247_456239383?list=d37fe1db5fda63607b&t=1m26s

Парадокс Браесса из этой книги (рис 1.9) также можно привести в этом разделе (парадокс Браесса отдельно будет и в конце главы, но там акценты немного на другом – на устойчивости и нащупывании) и приводить его лучше не в варианте 20-40 минут на нижних ребрах, а так как предписываем модель стабильно динамики Нестерова. В книге модель изложена неточно. Точнее было бы так – время прохождения нижних дорог 20 минут, пропускная способность половина от потока желающих.

@Ирина Подлипнова и/или Александр Филатов

§ 2 Парадокс Кондорсе и теорема Эрроу

Как минимум стоит рассказать как в этой книге (примеры взять)

https://savvateev.xyz/books/zam_eko/zam_eko.pdf

Пример еще можно взять вот отсюда

В. Босс Лекции по математике Т. 12 Контрпримеры и парадоксы. п. 10.4 Теорема

Эрроу. Видео по этим материалам

https://vk.com/video-56385969_456239658?t=29s

Есть отдельное подробное видео

<https://rutube.ru/video/859968fb1e5cc0a13658c8263ffa4f29/>

@Александр Филатов и/или Иван Козицын

§ 3 Принцип Гудхарата

Совсем немного сказать, если получится сделать как-то научно. Если не получится, то не надо включать

<https://www.securitylab.ru/analytics/540344.php>

тут все довольно легко гуглится и ChatGPT неплохо тут тоже дает ответы...

Немного пофилософствовать о переобучении, U-образной кривой в Машинном обучении. Эффекты в чем-то похожи. Когда мы думаем, что функционал один (построенный по обучающей выборке), но на самом деле он другой (построенной на тестовой, чтобы избежать переобучения), то и возникает упомянутое переобучение, когда мы берем в качестве функционала (обучающего датасета) то, что раньше выполняло роль тестового, мы автоматически теряем контроль над переобучением. Хорошая возможность в целом тут немного пофилософствовать о том, как устроено (машинное) обучение и сопоставить этот эффект с тем, что имеет место в целом в обучении с какими-то целевыми показателями. Примеры легко находятся...

Можно немного и про IQ-тесты сказать в этой связи

<https://yandex.ru/video/preview/2303296238350412218>

Также можно привести историю про “квадрат К.В. Рудакова” и индекс Хирша (как проинтерпретировать индекс Хирша). Отсортируем все статьи данного ученого по числу цитирований и пронумеруем их по принципу – первая статья (самая цитируемая), вторая – вторая по цитируемости и т.д. Далее по оси абсцисс будем откладывать номер статьи, а по оси ординат откладывать количество ссылок на нее. Тогда полученный график вполне характеризует публикационную активность ученого. Очевидно, что если один график лежит строго под другим, то ученый с более высоким графиком, во всех смыслах более цитируемый. Но в общем случае, так сравнивать не получится, поэтому графику ставят в соответствие одно число (на множестве чисел уже есть отношение полного порядка и ученых можно сравнивать по цитируемости), которое определяется как длины стороны максимально большого квадрата, который можно вписать под график с левой нижней вершиной в начале координат и правой верхней вершиной на графике. Это и будет индекс Хирша ученого.

@Константин Цыбиков и Ирина Подлипнова

§ 4 Парадокс глобализации (трилемма глобализации)?

Совсем немного сказать, если получится сделать как-то научно. Если не получится, то не надо включать

https://ru.wikipedia.org/wiki/%D0%9F%D0%B0%D1%80%D0%B0%D0%B4%D0%BE%D0%BA%D1%81_%D0%B3%D0%BB%D0%BE%D0%B1%D0%B0%D0%BB%D0%B8%D0%B7%D0%B0%D1%86%D0%B8%D0%B8

тут все довольно легко гуглится и ChatGPT неплохо тут тоже дает ответы...

@Александр Филатов

§ 5 Закон $\sim 1/\sqrt{n}$ – чтобы с точностью 10% определить победителя во втором туре выборов достаточно опросить порядка 100 респондентов!

1. Задача о выборах или как оценить до самих выборов кто победит на выборах с двумя кандидатами? “Республиканец Дональд Трамп победил на выборах президента США (2016 года) совершенно непредвиденно – почти все опросы отдавали победу демократу Хиллари Клинтон.” Такого типа заголовками пестрили СМИ в 2016 году. И дело тут не только в особенности избирательной системы США, в которой в итоге победил кандидат, набравший меньше голосов, чем оппонент (это особенно странно, учитывая, что сложности в создании “справедливой” системы голосования начинаются с трех кандидатов, см., например, параграф про Теорему Эрроу и парадокс Кондорсе). А в том еще дело, что в ряде штатов не оправдались результаты предварительных опросов. С чем это может быть связано? Отбрасывая трудно контролируемые факторы (например, что часть респондентов могли стесняться ответить, что они будут голосовать за Трампа), сосредоточимся на главном – во всех этих штатах (где итоговый результат голосования не совпал с предварительным) наблюдалась близость результатов двух кандидатов. В целом это довольно типично для выборов США, где кандидаты особенно подвержены конъюнктуре (стараясь понравиться большей части избирателей), и по мере приближения момента выборов стремятся по целому ряду вопросов сблизиться в своих позициях со вкусами “медианного избирателя” (см. параграф про Даунсовскую модель пространственной конкуренции)... Именно близость результатов кандидатов при опросах мы и возьмем за отправную точку далее, чтобы объяснить количественно, что могло произойти.

Итак, рассмотрим конкретный штат (несколько десятков миллионов человек). Пускай из всех потенциально голосующих людей доля p предпочитает Трампа и доля $1 - p$ – Клинтон. Если случайно опрашивается несколько десятков тысяч человек, то получают набор случайных величин – результатов ответов респондентов. Почему это случайные величины? Потому что считается, что каждый респондент выбирается случайно из числа всех голосующих, и вероятность того, что будет выбран человек, который поддерживает Трампа будет p , а Клинтон, стало быть, — $1 - p$. Тут резонно было бы заметить, что после того, как опросят первого респондента пропорция меняется (ведь второй раз его уже не получится по правилам опросить), и уж тем более пропорция поменяется, когда опросят несколько десятков тысяч человек. Однако, если вспомнить, что в целом в штате голосовать могут десятки миллионов человек, то получается, что мы сейчас говорим о поправках в определении p порядка 0.001. Чем можно пренебречь, как будет видно из дальнейшего.

Для удобства поставим в соответствие k -му респонденту ($k = 1, \dots, n$) Бернуллиевскую случайную величину ξ_k , принимающую всего два значения

$$P(\xi_k = 1) = p, \quad P(\xi_k = 0) = 1 - p.$$

Имеется аналогия с монеткой, где вероятность успеха равна p . Результат опроса респондента равносителен подбрасыванию такой монетки. Респонденты опрашиваются независимо – монетка подкидывается независимо. Оценить неизвестный параметр p – вероятность успеха (долю голосующих за Трампа) можно совершенно естественно через частоту:

$$\hat{p} = \frac{1}{n} \sum_{k=1}^n \xi_k.$$

В общем случае (более сложных моделей эксперимента) такие оценки получаются из *принципа максимума правдоподобия* – при фиксированном значении параметра (в нашем случае p) выписывают вероятность того, что будет наблюдаться конкретная последовательность $\{\xi_k\}_{k=1, \dots, n}$

$$p^{\sum_{k=1}^n \xi_k} (1 - p)^{n - \sum_{k=1}^n \xi_k}.$$

Затем находят такое значение параметра $p = \hat{p}(\{\xi_k\})$, при котором эта вероятность максимальна. Эту оценку $\hat{p}(\{\xi_k\})$ называют *оценкой максимального правдоподобия*. Ее мы и привели выше. Впрочем, тут она имеет совершенно естественное происхождение.

2. Закон $\sim 1/\sqrt{n}$ – или главный закон математической статистики. Пожалуй, главная теорема математической статистики, доказанная Р. Фишером в 1922 году, грубо говоря, утверждает что такого типа оценки (максимального правдоподобия) при некоторых условиях регулярности и при больших n будут наилучшими, т.е. наиболее точно оценивающими неизвестный параметр. Чтобы понять, что это значит, приведем сразу основной результат, касающийся этой оценки (небольшие числовые множители перед корнями для наглядности мы опустили).

Теорема 2.5.1 (доверительный интервал). С вероятностью $\geq 1 - \delta$ при достаточно больших n имеют место неравенства:

$$\hat{p} - \sqrt{\frac{p \cdot (1-p) \ln \delta^{-1}}{n}} \lesssim p \lesssim \hat{p} + \sqrt{\frac{p \cdot (1-p) \ln \delta^{-1}}{n}}.$$

Или в немного более практичном варианте

$$\hat{p} - \sqrt{\frac{\hat{p} \cdot (1-\hat{p}) \ln \delta^{-1}}{n}} \lesssim p \lesssim \hat{p} + \sqrt{\frac{\hat{p} \cdot (1-\hat{p}) \ln \delta^{-1}}{n}}.$$


Грубо говоря, оценки максимального правдоподобия позволяют (асимптотически) наиболее точно (с наикратчайшим доверительным интервалом) локализовать оцениваемый параметр (или даже параметры) в приведенном выше смысле.

Для неподготовленного читателя приведенная теорема едва ли что-то прояснит. Почему именно такие оценки получаются? Ответ на этот вопрос дает одна из самых замечательных теорем теории вероятностей, входящая по многим опросам в топ-10 теорем в математике в целом, – *Центральная предельная теорема* (ЦПТ). Ее мы приведем с необычной и упрощенной схемой доказательства в конце параграфа. А сейчас постараемся объяснить Теорему 2.5.1 из более простых соображений (в категориях “с большой вероятностью” и без попытки количественно описывать что это значит).

Начнем с того, что любая случайная величина X , у которой есть математическое ожидание μ и дисперсия σ^2 , с большой вероятностью будет принимать значения в следующем диапазоне $[\mu - 3\sigma, \mu + 3\sigma]$, что можно записать и таким образом: с большой вероятностью (небольшие числовые константы, как и раньше опустили):

$$\mu - 3\sigma \lesssim X \lesssim \mu + 3\sigma.$$

Приведенный ниже график функции плотности распределения количественно демонстрирует сказанное выше для *нормальной случайной величины* (об этом точнее мы скажем в конце параграфа) – скажем, в отрезке $[\mu - 3\sigma, \mu + 3\sigma]$ нормальная случайная величина будет принимать значения с вероятностью больше 0.99. Для других случайных величин числа немного могут меняться, но для нас сейчас это не принципиально.



Вернемся к случайной величине ξ_k . Легко проверить, что ее математическое ожидание, по определению, равно

$$M \xi_k = 1 \cdot p + 0 \cdot (1 - p) = p,$$

а дисперсия, по определению, равна

$$D \xi_k = M[\xi_k^2] - (M \xi_k)^2 = [1^2 \cdot p + 0^2 \cdot (1 - p)] - (p)^2 = p \cdot (1 - p).$$

Математическое ожидание – линейно. Это значит, что

$$\mu = M \hat{p} = \frac{1}{n} \sum_{k=1}^n M \xi_k = p.$$

Дисперсия суммы независимых случайных величин, равна сумме дисперсий. Действительно,

$$D(X + Y) = M[(X + Y)^2] - (M(X + Y))^2 = M[X^2] + M[Y^2] - (MX)^2 - (MY)^2 + 2M[X \cdot Y] - 2MX \cdot MY.$$

В виду независимости X и Y математическое ожидание произведения равно произведению математических ожиданий, т.е. $M[X \cdot Y] = MX \cdot MY$ (этот результат, в свою очередь, следует из того, что вероятность произведения независимых событий, по определению, равна произведению вероятностей этих событий), что и доказывает

$$D(X + Y) = DX + DY.$$

С помощью математической индукции это утверждение обобщается на любое количество слагаемых. Учитывая это обстоятельство и то, что $D(\alpha X) = \alpha^2 DX$, где α – число, получим

$$\sigma^2 = D\hat{p} = \frac{1}{n^2} \sum_{k=1}^n D\xi_k = \frac{p \cdot (1-p)}{n}.$$

Но тогда с большой вероятностью

$$\mu - 3\sigma \lesssim \hat{p} \lesssim \mu + 3\sigma,$$

т.е. с большой вероятностью

$$p - 3\sqrt{\frac{p \cdot (1-p)}{n}} \lesssim \hat{p} \lesssim p + 3\sqrt{\frac{p \cdot (1-p)}{n}}.$$

Мы получили почти то что написано в первой системе неравенств Теоремы 2.5.1 (как и договаривались, на логарифмические множители под корнем внимание не обращаем – для их понимания уже без ЦПТ не обойтись). Осталось только поменять местами в полученном тут двойном неравенстве $\hat{p}$ и p . Чтобы получить вторую систему неравенств в этой теореме можно воспользоваться первой системой неравенств подставляя в выражение $p \cdot (1 - p)$ вместо параметра p его оценку $\hat{p}$.

Несмотря на некоторую легкость в рассуждениях, важно подчеркнуть универсальность полученного вывода. Все что мы сейчас описали ($\sim 1/\sqrt{n}$ близость оценки к оцениваемому параметру) имеет место для подавляющего числа постановок задач оценивания неизвестных параметров по выборке объема n .

3. Объяснение результатов выборов в США в 2016 году и беседа с Президентом России. Вернемся теперь к выборам в США. Как мы уже писали ранее $n \simeq 10000$ респондентов (несколько десятков тысяч респондентов мы для наглядности перевели в 10 000), а $p \simeq 0.5$ (за Трампа и Клинтон было приблизительно поровну голосов). Получается, что точность оценки

$$p \simeq 0.5 \pm \frac{1}{\sqrt{n}} = 0.5 \pm 0.01.$$

Отсюда, во-первых, мы получаем, что поправкой в определении p порядка 0.001, связанной с небольшим нарушением пропорции в результате опросов, действительно, можно пренебречь. А, во-вторых, и это главное, в случае когда разница между двумя кандидатами минимальна, чтобы правильно определить по опросам $n \simeq 10000$ респондентов кто победит с большой вероятностью, нужно, чтобы за одного из кандидатов проголосовало не менее 51% населения. Что, как раз, места и не имело.

Забавно, что во многих ситуациях достаточно опросить намного меньше респондентов, чтобы определить победителя. И один такой пример мы приведем здесь.

История началась с того, что в 2024 году один из соавторов книги поучаствовал в Конгрессе учителей физики в Сириусе, который организовывал МФТИ. Исследуя потребность школ в регионах страны в учителях физики он задавал один и тот же вопрос встречающимся на конгрессе учителям (представителям разных регионов страны): хватает ли в Вашей школе и территориально близких Вам школах учителей физики? За несколько дней конгресса удалось опросить около 100 учителей. Около 90

человек ответило, что “не хватает” (тут следует пояснить, что, как правило, учителя отвечали по совокупности школ, беря, видимо, худшие из известных им).

В конце 2024 года на мероприятии спутнике после Конгресса молодых ученых в разговоре этого же соавтора книги с Президентом России Владимиром Владимировичем Путиным довольно неожиданно возник как раз тот же самый вопрос: хватает ли сейчас учителей физики в школах? На что упомянутый соавтор сказал, что не хватает, и у него достаточно высокая степень уверенности в этом, хотя опрошено было всего 100 человек. Рассуждения, которые были озвучены, следующие.

Поскольку было опрошено около 100 учителей, то точность оценки в 90% школ не хватает учителей – около 10%! То есть хотя точность и невысокая, но даже в самом оптимистичном сценарии получается, что в 80% школ все равно не хватает. Что позволяет в целом говорить о том, что не хватает. Но можно сказать даже точнее! Поскольку большинство говорили, что “не хватает”, то дисперсия оценки $p \cdot (1 - p)$ при $p \simeq 0.9$ заметно ближе к нулю, чем при $p \simeq 0.5$, и доверительный интервал получается еще короче, т.е. опрашивать 100 человек для 10% точности нужно в худшем случае, когда $p \simeq 0.5$, т.е. когда дисперсия $p \cdot (1 - p)$ – максимальна. Для $p \simeq 0.9$ и 10% точности хватит и половины от 100 человек, т.е. около 50 человек.

На самом деле, такие эксперименты, каждый из Вас, уважаемые читатели, может делать в совершенно разном контексте. Для расширения списка примеров приведем один из первых опытов того же соавтора.

В 2012 году гуляя по городу Будве (Черногория) он проверял знает ли местное население русский язык, задавая вопрос на русском “сколько времени”. Более 40% активного населения города Будвы (встречающегося на улицах) охотно (и часто вполне успешно) пытались ответить по-русски.

Главная мысль, которую должен был донести этот параграф в своей основной части – это закон $\sim 1/\sqrt{n}$ – точность оценки убывает с объемом выборки по такому закону... Это один из важнейших законов, которые многократно встречаются в жизни в самых разных контекстах, где есть что-то случайное... Получается этот вывод просто из свойства дисперсии – дисперсия суммы независимых случайных величин равна сумме дисперсий. Сейчас это проходят в 10 классе школы. И несмотря на то, что это известно еще в школе, по-настоящему, оценить значимость этого закона можно, видимо, только осознав то, что вся Математическая статистика, Машинное обучение, а теперь еще и Искусственный интеллект (ИИ) имеют в своей основе этот закон. В этом параграфе (в основной его части) мы ограничились простейшей демонстрацией этого закона на, так называемой, схеме испытаний Бернулли.

3.* Федеративная оптимизация и закон $\sim 1/\sqrt{n}$. Выше при выводе закона $\sim 1/\sqrt{n}$ мы, казалось бы, существенным образом опирались на то, что все случайные величины $\{\xi_k\}_{k=1, \dots, n}$ были *независимы* (дисперсия суммы равна сумме дисперсий) и одинаково распределены (использовалось при подсчете математического ожидания и дисперсии). Однако, совсем несложно догадаться, что одинаковая распределенность, в действительности, не важна. Важно уметь считать математическое ожидание и оценивать дисперсию. Действительно, если, например,

$$P(\xi_k = 1) = p_k, \quad P(\xi_k = 0) = 1 - p_k,$$

то приведенные ранее формулы преобразуются следующим образом:

$$\begin{aligned}\hat{p} &= \frac{1}{n} \sum_{k=1}^n \xi_k, \\ \mu &= M\hat{p} = \frac{1}{n} \sum_{k=1}^n M\xi_k = \frac{1}{n} \sum_{k=1}^n p_k, \\ \sigma^2 &= D\hat{p} = \frac{1}{n^2} \sum_{k=1}^n D\xi_k = \frac{1}{n^2} \sum_{k=1}^n p_k \cdot (1 - p_k) \leq \frac{1}{2n}, \\ \hat{p} - \sqrt{\frac{\ln \delta^{-1}}{2n}} &\lesssim \mu \lesssim \hat{p} + \sqrt{\frac{\ln \delta^{-1}}{2n}}.\end{aligned}$$

Но зачем и где это может понадобиться? В предыдущем пункте мы уже упоминали, что закон $\sim 1/\sqrt{n}$ является важным, например, в ИИ. Только в приложениях, связанных с большими данными, этот закон требует некоторых корректировок. А именно, выше мы не учитывали, что оцениваемых параметров может быть много (у нас оцениваемый параметр был всего один). Ведь чем больше параметров, тем меньше можно сделать ошибку аппроксимации используемой параметрической модели (в описанной нами схеме испытаний Бернулли такой ошибки не было вовсе, в общем же случае, особенно, в приложениях к моделям ИИ такие ошибки играют ключевую роль), еще говорят, тем точнее можно спроектировать описываемый процесс на данную модель. С ростом числа оцениваемых параметров (обозначим это число через d) в закон $\sim 1/\sqrt{n}$ требуется вносить поправку, зависящую от d (в современных неасимптотических версиях такого типа результаты и более точные имеются, например, в работах В.Г. Спокойного):

$$\sim \sqrt{\frac{d}{n}}.$$

Отсюда получаем, что чем больше параметров d надо оценивать, тем больше требуется и объем обучающей выборки n . Когда обучаются, например, *большие языковые модели*, параметров (весов нейронной сети *трансформерного* типа) может быть триллион. Понятно, что для достижения хорошего качества обучения тут требуется использовать огромные *датасеты*, хранить которые на одном устройстве (сервере), как правило, не представляется возможным (как из-за объемов, так и из-за *приватности* данных). Помогает тут, например, *Федеративное обучение*, которое мы подробнее обсудим в главе 4. В первом приближении идея очень простая, если по каким-то причинам нет возможности все данные (выборку) для обучения собрать на одном устройстве, то можно наладить процесс взаимодействия между сервером (на котором хранится обучаемая модель ИИ) и устройствами, на которых хранятся данные. В процессе обучения постоянно требуется пересылать между устройствами и сервером огромные массивы данных, поэтому возникает естественное желание как-то сэкономить на пересылке.

Для большей наглядности, максимально упростим ситуацию, чтобы пояснить главную идею. А именно, пускай серверу нужно посчитать число

$$\mu = \frac{1}{n} \sum_{k=1}^n p_k,$$

а числа $p_k \in [0, 1]$ хранятся на $k = 1, \dots, n$ устройствах соответственно, где $n \simeq 60000$.

Будем считать, что на каждое число отведена память в один байт (то есть 8 бит).

Понятно, что если каждое устройство пошлет на сервер один байт информации (8 бит), то сервер легко посчитает μ . Можно ли тут как-то сократить объем пересылаемой информации, и если можно, то насколько?

Удивительно, но ответ, который следует из

$$\frac{1}{n} \sum_{k=1}^n \xi_k - \sqrt{\frac{\ln \delta^{-1}}{2n}} \lesssim \mu \lesssim \frac{1}{n} \sum_{k=1}^n \xi_k + \sqrt{\frac{\ln \delta^{-1}}{2n}},$$

где

$$P(\xi_k = 1) = p_k, \quad P(\xi_k = 0) = 1 - p_k,$$

положительный! А именно, каждое устройство независимо от остальных “подбрасывает свою монетку”, с вероятностью выпадения орла равной p_k . Это совсем несложно сделать, если уметь генерировать равномерно распределенную случайную величину на отрезке $[0, 1]$ – именно это, как правило, по умолчанию и делают генераторы случайных чисел, встроенные в разные библиотеки. Действительно, отмечаем на отрезке $[0, 1]$ точку p_k , если случайная величина попала левее этой точки, то $\xi_k = 1$, иначе $\xi_k = 0$. Далее все очевидно – вместо числа p_k (8 бит информации) каждый узел посылает 1 бит информации в виде случайной величины ξ_k . Сервер

считает $\frac{1}{n} \sum_{k=1}^n \xi_k$, и получает приемлемую оценку параметра μ . Чтобы убедиться, что такая оценка особо не уступает точной оценке, осталось только подставить в закон $\sim 1/\sqrt{n}$ число $n \simeq 60000$ и заметить, что это число будет совпадать по порядку с 2^{-8} .

Современные ИИ-гиганты, как правило, обладают кластерами, состоящими из сотен тысяч (а кто-то уже и из миллионов) вычислительных узлов, т.е. $n \simeq 60000$ – сейчас совсем уже не является какой-то заоблачной оценкой. Описанный выше прием позволил сжать объем передаваемой информации в 8 раз! Понятно, что так можно в целом округлять (вероятностное округление) все передаваемые числа – этот и похожие приемы в компьютерной математике называют *рандомизацией*, но в федеративной оптимизации появился специальный термин – *несмещенная компрессия*.

Часто числа p_k могут представлять какую-то тайну (особенно при работе с персонализированными данными людей). Нежелательно их напрямую пересылать. Описанный выше способ одновременно с сжатием дает лишь минимальную информацию об этих числах, насколько это возможно, сохраняя их, по сути, в тайне.

4. Центральная предельная теорема (ЦПТ) и окрестности.** К сожалению, несмотря на (надеемся 😊) понятность приведенных ранее доводов в справедливости закона $\sim 1/\sqrt{n}$, вряд ли у читателей осталось ощущение полного понимания... Лакуны в рассуждениях имеются, начиная с того, почему случайная величина с большой вероятностью будет принадлежать, скажем, отрезку $[\mu - 3\sigma, \mu + 3\sigma]$ и заканчивая уже более точными поправками вида $\ln \delta^{-1}$ в оценках доверительного интервала в Теореме 2.5.1.

Чтобы пояснить откуда все это берется далее мы приведем схему одного из самых изящных и поучительных доказательств *Центральной предельной теоремы* (ЦПТ), базирующегося на *принципе неподвижной точки* (навеянного способом доказательства на основе *метода ренорм-группы* из книги Коралова–Синая по случайным процессам), которые мы только знаем. Далее мы не приводим полного доказательства, а лишь демонстрируем идею того, почему возникает именно нормальное (Гауссовское) распределение в пределе (на наш взгляд, это наиболее интересное место в ЦПТ). В целом, можно насчитать десятки вариантов формулировок и доказательств ЦПТ. Отметим среди прочих также очень красивое геометрическую формулировку, принадлежащую Б. Клартагу (2007 год), связанную с явлением концентрации меры на изометричных выпуклых телах в многомерных пространствах.

Но вернемся, к схеме доказательства ЦПТ через принцип неподвижной точки. Предположим, что имеется совокупность независимых одинаково распределенных случайных величин $\{\xi_k\}_{k=1,\dots,n}$ с математическим ожиданием μ и дисперсией σ^2 .

Рассмотрим правильно отнормированную случайную величину

$$\frac{\sum_{k=1}^n (\xi_k - \mu)}{\sigma\sqrt{n}}.$$

Несложно заметить, что математическое ожидание этой случайной величины равно нулю, а дисперсия равна 1, и все это независимо от того, как выбрано n . Собственно, именно, чтобы добиться такой “независимости” и подбирался вид этой случайной величины (это и подразумевалось под “правильной нормировкой”). С этим шагом все вполне просто.

Далее, делается главный и наиболее сложный шаг, но зато самый изящный. Опирается он на предположение (без доказательства), что при $n \rightarrow \infty$ введенная отнормированная случайная величина (очевидно, зависящая от n , но с математическим ожиданием и дисперсией, не зависящими от n) сходится к некоторой случайной величине ξ (по распределению, то есть в пределе при $n \rightarrow \infty$ имеет такое же распределение, как ξ):

$$\frac{\sum_{k=1}^n (\xi_k - \mu)}{\sigma\sqrt{n}} \rightarrow \xi \text{ при } n \rightarrow \infty.$$

Какое тогда распределение имеет случайная величина ξ ? Чтобы ответить на этот вопрос заметим, что из

$$\frac{\sum_{k=1}^n (\xi_k - \mu)}{\sigma\sqrt{n}} \rightarrow \xi \text{ при } n \rightarrow \infty, \text{ следует } \frac{\sum_{k=1}^{2n} (\xi_k - \mu)}{\sigma\sqrt{2n}} \rightarrow \xi \text{ при } n \rightarrow \infty.$$

Последнюю формулу можно переписать вот таким образом:

$$\frac{1}{\sqrt{2}} \left(\frac{\sum_{k=1}^n (\xi_k - \mu)}{\sigma\sqrt{n}} + \frac{\sum_{k=1}^n (\xi_k - \mu)}{\sigma\sqrt{n}} \right) \rightarrow \xi \text{ при } n \rightarrow \infty.$$

Переходя к пределу в каждом слагаемом по отдельности **можно получить**, что предельная случайная величина ξ неизбежно должна удовлетворять такому равенству “по распределению”:

$$\frac{1}{\sqrt{2}}\xi + \frac{1}{\sqrt{2}}\xi = \xi,$$

которое следует “читать” следующим образом: если к случайной величине $\xi/\sqrt{2}$ прибавить независимую от нее случайную величину из того же распределения (отвечающего случайной величине $\xi/\sqrt{2}$), то должна получиться случайная величина, имеющая такое же распределение, как ξ .

Используя формулу полной вероятности можно получить из этого уравнения на ξ функциональное уравнение на плотность распределения $p_\xi(x)$ случайной величины ξ (при выводе использовалось то, что плотность распределения случайной величины $\xi/\sqrt{2}$ равна $p_{\xi/\sqrt{2}}(x) = \sqrt{2} p_\xi(\sqrt{2}x)$):


$$p_\xi(x) = 2 \int_{-\infty}^{\infty} p_\xi(\sqrt{2}(x-y))p_\xi(\sqrt{2}y)dy.$$

Решением этого уравнения является однопараметрическое (параметр $D > 0$) семейство функций Гаусса

$$p_\xi(x) = \frac{1}{\sqrt{2\pi D}} \exp\left(-\frac{x^2}{2D}\right).$$

Но мы знаем, что дисперсия случайной величины ξ должна быть равна 1. Отсюда можно вывести, что $D = 1$, т.е.

$$p_\xi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$$



Случайную величину ξ , имеющую такую функцию плотности распределения, называют стандартной нормальной случайной величиной и обозначают это обычно так $\xi \in N(0, 1)$, где первым аргументом подчеркивают, что математическое ожидание равно нулю, а вторым, что дисперсия равна 1. Понятно, что аналогично можно определить $N(\mu, \sigma^2)$, график плотности распределения которой мы ранее уже приводили. Собственно, с учетом всего вышесказанного *Центральная предельная теорема* (ЦПТ) может быть записана следующим образом.

Теорема 2.5.2 (Центральная предельная теорема). Для совокупности независимых одинаково распределенных случайных величин $\{\xi_k\}_{k=1, \dots, n}$ с математическим ожиданием μ и дисперсией σ^2 при некоторых, вполне естественных предположениях, имеет место следующая сходимость (по распределению) при $n \rightarrow \infty$:

$$\frac{\sum_{k=1}^n (\xi_k - \mu)}{\sigma\sqrt{n}} \rightarrow N(0, 1),$$

то есть случайная величина слева при больших n имеет плотность распределения “близкую” (в практическом смысле – а именно в смысле подсчета вероятностей всевозможных событий) к плотности нормального распределения (чем больше n , тем ближе)

$$p(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$$

Несложно показать, что Теорема 2.5.1 (в том числе появление $\ln \delta^{-1}$ под корнем) является прямым следствием ЦПТ – Теорема 2.5.2.

Если ξ_k имеет финитный (конечный) носитель распределения или хвосты функций плотности распределения случайных величин ξ_k убывают так же как у функции Гаусса, то приведенной теоремой с небольшими оговорками можно пользоваться на практике (то есть в стиле Теоремы 2.5.1) начиная с совсем небольших n , т.е. Теорему 2.5.2 можно понимать как неасимптотический результат (следует из неравенств концентраций Хефдинга и Бернштейна). Уже для экспоненциальных хвостов плотностей распределений ξ_k это не так. Особенно это не так, когда хвосты плотностей распределений ξ_k убывают степенным образом. В этом случае для практического применения ЦПТ рекомендуется уже использовать более продвинутые неравенства типа неравенств концентрации С.В. Нагаева.

В случае, если теряется независимость случайных величин $\{\xi_k\}_{k=1, \dots, n}$, то при некоторых важных на практике оговорках все же удастся получить аналоги приведенных выше результатов. Так, если последовательность $\{\xi_k\}_{k=1, \dots, n}$ будет

мартингал-разностью (важно в финансовой математике, а также при исследованиях сходимости различных процедур типа стохастического градиентного спуска – об этом мы будем говорить, например, в Главе 4), то практически все утверждения сохраняются без изменений, лишь с должной корректировкой фамилий авторов соответствующих результатов (так неравенство концентрации Хефдинга становится неравенством концентрации Азума–Хефдинга, а неравенство концентрации Бернштейна будет неравенством концентрации Бернштейна–Фридмана). Немного более сложным образом происходит обобщение на *марковские процессы*, которые нам будут активно встречаться в Главе 5. Тут также в целом все сохраняется, но замедляется скорость сходимости. А именно, эргодическая марковская цепь характеризуется временем перемешивания τ (выходом на стационарный режим). В частности, это время можно понимать как минимальное время, которое необходимо пройти марковскому процессу, чтобы сечения процесса можно было с хорошей точностью считать независимыми: ξ_k и $\xi_{k+\tau}$ – почти независимые случайные величины. В этом случае, почти все основные результаты типа ЦПТ и неравенств концентраций сохраняются, но скорость сходимости замедляется в τ раз.

§ 6 Парадокс Симпсона и процветание альтруистов

А.В. Марков Эволюция человека Т. 2

<https://cdn.img-gorod.ru/nomenclature/22/958/2295857.pdf> стр. 317 (будем называть это биологическим парадоксом, чтобы не путать со статистическим). Вот тут лучше поиграться с ChatGPT по поводу конкретных примеров. Он неплохо генерирует, просто надо подобрать что-то такое интересное политически... Правда, тут есть некоторый нюанс (если делать все аккуратно). А именно, используется теория родственного отбора Гамильтона (кстати, это дает хороший повод ее тут рассказать) – в простейшем виде можно без нее, но лучше все же потом и с ней рассказать, чтобы было более полное описание. Ну и взять пример чаек (пример по Ричарду Докинзу), которые живут стаями. Когда чайка видит еду она кричит и зовет сородичей (см., например, главу 5 в той же книге Маркова).

Но лучше дополнительно разобрать и статистический парадокс Симпсона

https://ru.wikipedia.org/wiki/%D0%9F%D0%B0%D1%80%D0%B0%D0%B4%D0%BE%D0%BA%D1%81_%D0%A1%D0%B8%D0%BC%D0%BF%D1%81%D0%BE%D0%BD%D0%B0

Шутки ради можно и это добавить:)

https://ru.wikipedia.org/wiki/%D0%A4%D0%B5%D0%BD%D0%BE%D0%BC%D0%B5%D0%BD_%D0%A3%D0%B8%D0%BB%D0%BB%D0%B0_%D0%A0%D0%BE%D0%B4%D0%B6%D0%B5%D1%80%D1%81%D0%B0

@Константин Цыбиков и Армен Бекларян (в части статистического парадокса)

§ 7 Ошибка выжившего

Историю пишут победители и из-за этого появляется смещение

<https://vertdider.tv/survivor-bias/>

тут все довольно легко гуглится и ChatGPT неплохо тут тоже дает ответы...

Надо поискать в классических книгах типа

https://psv4.userapi.com/s/v1/d/PLtt-OcJWN65nDY9kkP4fFSHjBjGgyJt7anulz131jt07tFESX_KTI5oUQ-8j73Kh1HnXSlmGVg6yex3adutov6ITTF4I_QuBEIJcAF8L74uOHQYu3srKQ/Paradox_v_teorii_veroyatnostey_i_matematicheskoy_statistike_2003__G_Sekey.pdf

про это и окрестности.

@Армен Бекларян Zamira Kholmatova

§ 8 Успешный успех или тяжелая работа?

Тут есть хороший пример про хоккеистов и астронавтов (но плохая озвучка, лучше найти тот же ролик, но с другой озвучкой ну и самим проработать эти примеры)

<https://rutube.ru/video/c56f6b7286eb5ee1edd7359a02159006/>

Грубо говоря, когда есть жесткая конкуренция и кандидаты приблизительно равны, роль случайности (везения) может играть преобладающую роль (в эксперименте с астронавтами).

@Армен Бекларян Zamira Kholmatova

§ 9 Регрессия к среднему

Строго говоря, это не совсем та регрессия, которую понимают в матстатистике... Так что терминология не должна смущать... Может название в этой связи стоит как-то и поменять... В целом можно кратко рассказать, используя

<https://vertdider.tv/regression-to-the-mean/>

Особо деталей много не надо.

Надо поискать в классических книгах типа

https://psv4.userapi.com/s/v1/d/PLtt-OcJWN65nDY9kkP4fFSHjBjGgyJt7anulz131jt07tFESX_KTI5oUQ-8j73Kh1HnXSIImGVg6yex3adutov6ITTF4I_QuBEIIJcAF8L74uOHQYu3srKQ/Paradoxy_v_teorii_veroyatnostey_i_matematicheskoy_statistike_2003_G_Sekey.pdf

про это и окрестности.

@Армен Бекларян [Zamira Kholmatova](#) (используется

<https://vertdider.tv/regression-to-the-mean/> + LLM-ки DeepSeek, Yandex Алиса)

Думаем, каждый из вас часто задавался вопросом: что эффективнее для работы команды – похвала или критика? На первый взгляд, все кажется очень простым: работа сделана хорошо – команду надо похвалить, плохо – нужно подсветить ошибки. Однако Даниэль Канеман в своей книге “Думай медленно... решай быстро” приводит пример с подготовкой летчиков. Опытные инструкторы, заметив, что похвала летчиков за мягкую посадку приводила к тому, что следующая посадка получалась хуже, пришли к выводу, что похвала не помогает обучению, а наоборот, даже вредит.

Может, действительно, есть случаи, когда похвала приводила к ухудшению результатов, а серьезный разговор, полный критики, – к успеху. А, возможно, это зависит от самих людей или от задач, которые они решают, и обратная связь не имеет сильного влияния на результаты? Сейчас мы с вами попробуем это выяснить.

Представьте, в Вашем подчинении работают несколько отделов – маркетинг, разработка, бухгалтерия и HR. В конце первого квартала Вы анализируете KPI и видите следующую картину:

Отдел	KPI	Отклонение от среднего
Маркетинг	95	+20
Разработка	85	+10
Бухгалтерия	50	-25
HR	70	-5

Средний KPI по компании – $(95+85+50+70)/4=75$. Вы решаете действовать:

- вы публично хвалите отдел маркетинга, выдаете премии сотрудникам и согласовываете дополнительный бюджет.
- команду разработки Вы также хвалите, но ставите задачу по ускорению выпуска продуктов.
- бухгалтеров не трогаете, они работают в привычном режиме.
- команде HR ставите жесткие условия о поднятии KPI до 90 и не согласовываете выделения бюджета на дополнительные мероприятия.

Проходит еще один квартал и результаты Вас удивили:

Отдел	KPI	Отклонение от среднего
Маркетинг	65	-5
Разработка	75	+5
Бухгалтерия	62	-5
HR	78	+5

Средний KPI по итогам квартала уже $(65+75+62+78)/4=70$.

Что же могло произойти?

- Рекордные результаты команды маркетинга в предыдущем квартале связаны со случайными факторами – рекламная компания “выстрелила”, удачно выстроились отношения с партнерами.
- Разработчики немного снизили темп из-за завершения работ по продукту.
- Команда HR подтянули свои результаты, несмотря на урезанный бюджет – наладили работу с рекрутинговыми агентствами и решили технические проблемы.


А что же это значит для руководителя? Этот пример наглядно показывает регрессию к среднему: очень высокие или очень низкие показатели со временем приближаются к среднему значению.

Слово “регрессия” происходит от латинского “regressio” – “обратное движение”, “отход”. В общем смысле о регрессии говорят, как об ухудшении, спаде, потере ранее достигнутых позиций. В данном контексте речь идет именно о регрессии к среднему – явлении, при котором очень высокие или очень низкие результаты при повторных замерах естественным образом приближаются к среднему значению.

Этот статистический феномен был замечен еще в конце XIX века благодаря любопытству одного учёного, который решил разобраться, как размер семян влияет на характеристики потомства. В 1877 году Фрэнсис Гальтон, британский исследователь, провёл серию масштабных экспериментов с семенами одного вида, но разного размера. Результаты оказались поразительными. Гальтон обнаружил, что потомство не стремится копировать размер родительских семян, а наоборот — «тянется» к некоему среднему значению:

- если родительские семена были очень крупными, их потомство оказывалось меньше родителей;
- если родительские семена были очень мелкими, их потомство вырастало крупнее родителей.

Вернемся к примеру с KPI отделов. Допустим, значения KPI имеет нормальное распределение со средним $\mu = 70$ и стандартным отклонением $\sigma = 10$. Мы уже видели в параграфе 5 данной главы, что почти все наблюдаемые значения (т.е. все возможные значения KPI) войдут в интервал $[\mu - 3\sigma, \mu + 3\sigma] = [40; 100]$. Однако, если внимательнее смотреть на распределение случайной величины (см. рисунок ниже), отражающей KPI, то можно заметить, что значения, расположенные ближе к центру, будут встречаться чаще.



Это объясняется самим определением вероятности события:

$P(a < x < b) = \int_a^b f(x)dx$, где $f(x)$ – это плотность распределения, а a и b – границы

интервала, для которого мы оцениваем вероятность. Если взять за плотность функцию распределения нормальной случайной величины со средним 70 и дисперсией 10, то можно вычислить вероятности для интервалов, например, (60, 80) и (40, 60):

$$P(60 < x < 80) = \int_{60}^{80} f(x)dx = \int_{60}^{80} \frac{1}{10\sqrt{2\pi}} e^{-\frac{(x-70)^2}{2 \cdot 10^2}} dx \approx 0,68$$

$$P(80 < x < 100) = \int_{80}^{100} f(x)dx = \int_{80}^{100} \frac{1}{10\sqrt{2\pi}} e^{-\frac{(x-70)^2}{2 \cdot 10^2}} dx \approx 0,16$$

Регрессия к среднему проявляется, когда мы наблюдаем экстремальные значения – те, что встречаются в “хвостах” распределения. В нашем примере, к редким значениям как раз относятся показатели отдела маркетинга в первом квартале, находящиеся в интервале (80, 100). Попадание в такой интервал возможно (мы уже выяснили с Вами, что почти все данные находятся в промежутке от 40 до 100), но вероятность такого попадания всего около 0.16. Во втором квартале отдел маркетинга понизил свои успехи до 65 баллов, что входит в интервал (60, 80), попасть в которой вероятность уже намного выше.

Результаты стараний каждого отдела как от стабильных (навыки, качество работы), так и от случайных факторов (везение, болезни, настроение). Поэтому, если в первом квартале Вы добились успеха, то это не обязательно означает, что во втором Вам также повезет. Это чем-то похоже на ожидание результата от подбрасывания монеты. Представьте, что Вы бросаете монету. Получив орла после двух бросков, не стоит ожидать получения орла и в третьем – вероятность получения орла осталась такой же.

Тем не менее, с подбрасыванием монеты связан очень интересный парадокс. Предположим, что Вы теперь бросаете две монеты. Пусть событие А – “на первой монете выпал орел”, событие В – “на второй монете выпал орел” и событие С – “только

на одной монете выпал орел”. Тогда события А, В и С попарно независимы, но любые два из них однозначно определяют третье. Почему это так? Мы сейчас проверим.

А и В независимы, так как результаты бросания одной монеты не влияют на результаты бросания другой. С другой стороны, события А и С (как и события В и С) кажутся зависимыми, но это не так. Они независимы, так как $P(AC) = P(A)P(C) = 1/4$ (и аналогично $P(BC)$). Но мы также можем заметить, каждое событие из трех происходит тогда и только тогда, когда происходит какое-то одно событие из двух других. Этот парадокс показывает нам, что попарная независимость событий не влечет за собой независимость в совокупности.

Тот же недостаток интуиции, из-за которого мы предполагаем зависимость при ее отсутствии, мешает нам увидеть общую закономерность, проявляющуюся повсюду. Регрессия к среднему как раз и выступает как математическая закономерность, присущая любым данным с вариативностью. Она напоминает нам, что не стоит делать выводы на основе одного всплеска или провала. Гораздо важнее увидеть полную картину и создать условия для стабильного получения хороших результатов.

§ 10 Парадокс формулы Байеса

Кратко рассказать, используя

<https://vertdider.tv/bayes-theorem/>

Мотивация простая, правильно интерпретировать условия задачи. Людям принимающим решения очень важно не делать поспешных выводов на основе получаемой информации (тут, в некотором смысле, похожая должна быть мораль как и в случае статистического парадокса Симпсона и других парадоксов, приведенных выше, связанных с восприятием данных).

Надо поискать в классических книгах типа

https://psv4.userapi.com/s/v1/d/PLtt-OcJWN65nDY9kkP4fFSHjBjGgyJt7anulz131jt07tFESXKTI5oUQ-8j73Kh1HnXSIImGVg6yex3adutov6ITTF4I_QuBEIJcAF8L74uOHQYu3srKQ/Paradoxu_v_teorii_veroyatnostey_i_matematicheskoy_statistike_2003_G_Sekey.pdf

про это и окрестности.

@Армен Бекларян


§ 11 Статистико-психологические парадоксы

Парадокс отношения к риску

<https://yandex.ru/video/preview/10580185694961541296> (отношение к риску)

Повторяемость эксперимента разрешает парадокс...

Парадокс страхования и Петербургский парадокс (из т. 12 книги В. Босса)



оснований судить об одноразовой игре. Средние значения продуктивно работают в других ситуациях, но не здесь.

Рассмотрим упрощенный аналог. Монета бросается один раз, и падает плашмя с вероятностью $1 - 2^{-100}$. Выигрыш при этом составляет 1 рубль. На ребро монета становится с вероятностью 2^{-100} , и тогда выигрыш равен 2^{300} рублей. Матожидание выигрыша $\sim 2^{200}$. Но, очевидно, больше рубля за участие в игре платить глупо. Потому что событие, имеющее вероятность 2^{-100} «никогда» не случается, и какая разница, сколько за него обещано. Использование матожидания оказывается просто не к месту. ►

Примечательно, что вокруг «Петербургского парадокса» было сломано немало копий при участии великих математиков, ошибавшихся, безусловно, по уважительным причинам.

6.3. Подоплека независимости

Что-то можно взять из книги Г. Секея Парадоксы в теории вероятностей и математической статистики (Парадокс страхования).

https://psv4.userapi.com/s/v1/d/PLtt-OcJWN65nDY9kkP4fFSHjBjGgyJt7anulz131jt07tFESXKTI5oUQ-8j73Kh1HnXSIImGVg6yex3adutov6ITTF4I_QuBEIJcAF8L74uOHQYu3srKQ/Paradox_v_teorii_veroyatnostey_i_matematicheskoy_statistike_2003_G_Sekey.pdf

В частности, там как раз более интересно написано про парадокс страхования.

https://chatgpt.com/s/t_699ac3d4b25c8191afd0bc3d532b3cef

@Армен Бекларян

§ 12 Шесть рукопожатий

Кратко рассказать, используя

<https://rutube.ru/video/855c8c6c29b0f639386d385a5003d764/>

Особо деталей много не надо.

Но!!! Очень важно сказать, что есть определенные статистические закономерности (надежность сетей, степенные законы распределения числа соседей и т.п.) и парадоксы (парадокс дружбы в книге С. Пейджа Модельное мышление https://psv4.userapi.com/s/v1/d/HLoKq5X649HCQNnpNrxTKKbCh33HXG39f_CsJUleazxXWJiD4aNaxQrfD0aylzl1KZxebT-N2ImJ1wpExi-_216cwMbXNuVsHgY7fFM6wujOD4ubMyrAKw/Skot_Peydzh_Modelnoe_myshlenie_2020.pdf Глава 10) в различных сетях, например, социальных (если они нарушаются, то можно детектировать какую-то вредоносную деятельность, привести конкретные примеры). Чтобы понять, откуда берутся эти статистические закономерности, можно упомянуть модель предпочтительного присоединения (но не только с этой моделью связан закон), как модель роста изучаемой сети (деньги к деньгам), которое и порождает степенные законы, гигантскую компоненту и фазовые переходы.

Можно рассказать реальную историю с книжкой А.М. Райгородского Н. Литвак “Кому нужна математика”. Как А.М. Райгородский подарил ее мне, я подарил ее своей знакомой из Народного фронта в Сбере у нее эту книгу увидев при встрече попросил Д.С. Песков, а у него, в свою очередь, Президент. Так образом книга, в которой описывается как раз эффект 6 рукопожатий прошла цепочку 4 “рукопожатий” и оказалась у первого лица:) Собственно, книга А.М. Райгородского Н. Литвак тут как раз и может также использоваться как источник, из которого можно брать материал.

@Иван Козицин (я готов) или/и Армен Бекларян

§ 13 Парадокс Браесса

Важно ввести понятие социального оптимума, обсудить эффективность равновесия по Парето и отметить, что равновесие по Нэшу не обязано быть эффективным по Парето (что имеет место и для дилеммы заключенного, но об этом мы уже говорили в параграфе 5 Главы 1).

Лучше рассказать парадокс Браесса двух вариантах моделей (Стабильной динамики и Бэкмана)

<https://www.kommersant.ru/doc/4425783> (отсюда можно взять рассказ про то как образуются пробки на примере сети дорог из одного источника и стока в самом начале статьи -- пример по модели стабильной динамики Нестерова-деПальмы, https://elementy.ru/nauchno-populyarnaya_biblioteka/431798/Kak_borotsya_s_probkami?ysclid=ml3q8e29t2575100556

https://vk.com/video-135454514_456242213


https://vk.com/video-56385969_456239694?t=0s

При этом для модели стабильной динамики важно в целом по-простому объяснять как образуются пробки (на примере модели Нестерова с одним источником, одним стоком и двумя путями) <https://arxiv.org/pdf/1405.7630> вот тут есть парадокс Браесса в модели Нестерова-деПальмы (пример 1 и 2 в п. 6), да и само описание модели (в этом же пункте). Парадокс Браесса по модели Бэкмана тоже стоит объяснить.

** В главе 3 мы вернемся к этим моделям в связи с платными дорогами, поэтому тут было бы здорово сделать отступление и привести сюжет про нащупывание равновесия в парадоксе Браесса и в целом в популяционных играх загрузки

<https://www.mdpi.com/2227-7390/11/4/858> (есть и на arxiv.org).

Тут приведен пример логит-динамики (для модели Бэкмана). Про это важно отдельно сказать. При предельном переходе (дисперсия шума Гумбеля стремится к нулю) получится как раз BR-динамика (Best Response, динамика наилучших ответов, о которой довольно много говорили в Главе 1). Логит динамика сходится к стохастическому равновесию, поэтому, чтобы сойтись к нужному равновесию нужно этот предельный переход сделать. Однако, если равновесие не единственно, пример “пенсне В.И. Швецова”, то чтобы отобрать единственное как раз и помогает логит динамика. Она сходится к тому, что приведено на рисунке (ниже). Примечательно тут еще схема гумбелевского шума. Важно объяснить с точки зрения теории дискретного выбора (Discrete choice theory) почему тут получается именно такой шум. Ответ – люди часто ориентируются на худший прогноз из множества (то есть такие минимаксеры). Ну и гумбелевский шум как раз подобно нормальному шуму (который устойчив относительно суммирования) устойчив относительно взятия max. Про это можно как раз взять фрагмент текста из книги М.Б. Лагутин Наглядная математическая статистика https://cmd.inp.nsk.su/~epifanov/stat/lagutin_2015.pdf параграф 2 Главы 4 Распределение экстремальных значений (теорема 1 в части Гумбеля можно привести с док-вом в виду простоты).



Какое реализуется равновесие? Ответ: $0.25, 0.25, 0.25, 0.25$.

@Ирина Подлипнова